

# Reconocimiento de emociones en rostros

Trejo Fuenes Sergio Marcelino \*

\* Centro de Investigaciones en Óptica, León, Gto (e-mail: sergiotrejo@cio.mx).

Torres-López Diana Jazmin \*\*

\*\* Centro de Investigaciones en Óptica, León, Gto (e-mail: dianatl@cio.mx).

Coronado-Andrade Allan Christopher \*\*\*

\*\*\* Centro de Investigaciones en Óptica, León, Gto (e-mail: allanca@cio.mx).

---

**Abstract:** Este estudio se enfocó en desarrollar y evaluar un modelo de red neuronal convolucional para la clasificación de cinco emociones específicas (angry, fear, happy, sad, surprise) utilizando imágenes faciales de 48x48 píxeles de la base de datos FER-2013. La arquitectura del modelo incluye varias capas convolucionales seguidas de capas de pooling y capas densas. Se utilizó el optimizador Adam y la función de pérdida Sparse Categorical Crossentropy. La evaluación del modelo reveló una capacidad variable para identificar correctamente las emociones, con un rendimiento destacado en las emociones 'happy' y 'surprise', mientras que las emociones 'sad', 'fear' y 'angry' mostraron un reconocimiento menos efectivo. La exactitud general del modelo fue del 0.52, indicando un rendimiento moderado. Estos resultados sugieren que, aunque el modelo es competente en ciertas áreas, hay espacio para mejoras, especialmente en las emociones con menor rendimiento.

*Keywords:* Emociones faciales, redes neuronales convolucionales, inteligencia artificial (IA).

---

## 1. INTRODUCCIÓN

El reconocimiento de emociones faciales es un proceso crucial para muchas aplicaciones y aún no está resuelto. Históricamente, el reconocimiento emocional se ha conseguido habitualmente mediante técnicas de inteligencia artificial como las Redes Neuronales Convolucionales. Sin embargo, este enfoque es bastante caro en términos de potencia y complejidad computacional.

De acuerdo a nuestra investigación, existen por lo menos cuatro conjuntos de datos públicos, FER-2013, RAF-DB, AffectNet y CK+, donde se pueden detectar siete emociones faciales.

Existen en la literatura varios modelos exitosos de CNN y redes neuronales convolucionales profundas (DCNN) de última generación para el reconocimiento de emociones, como VGG16 Simonyan and Zisserman (2014), ResNet50 Long et al. (2015) e Inception v4 Szegedy et al. (2017). Aunque estos modelos aportan mucha innovación al campo, necesitan una alta potencia computacional debido a su complejidad y la gran cantidad de parámetros requeridos.

### 1.1 Trabajos Relacionados

Esta sección resume la literatura sobre tres dimensiones cruciales para las tareas de reconocimiento de expresiones faciales: conjuntos de datos de imágenes de expresiones faciales, enfoque de aprendizaje profundo y arquitectura CNN.

### 1.2 Bases de datos

Los conjuntos de datos públicos son escasos y son una de las principales variables que determinan en gran medida el rendimiento de los modelos de IA. Identificamos cuatro conjuntos de datos diferentes en la literatura con diferentes características. Estas diferencias son el método de anotación, número de imágenes, resolución, género, raza, edad, etc. La Tabla 1 muestra las cuatro bases de datos utilizadas en nuestros experimentos y sus características.

### 1.3 FER-2013

Reconocimiento de expresión facial 2013 (FER-2013) es uno de los primeros conjuntos de datos de la literatura, creado por Kaggle en 2013. El conjunto de datos se dividió en siete expresiones de emociones (6 básicas y neutrales) con 28709 imágenes de trenes y 3589 imágenes de prueba. Estas imágenes se recopilaron de Internet y un algoritmo

anotó automáticamente las etiquetas de las emociones [7]. Las imágenes son de  $48 \times 48$  píxeles con colores en escala de grises. En la Figura 2 se muestran ejemplos de FER-2013.

| Database        | Environment | Images    | Position             | Colour    | Emotion Classes                                     | Annotation Methods           |
|-----------------|-------------|-----------|----------------------|-----------|-----------------------------------------------------|------------------------------|
| AffectNet-7 [4] | Web         | 1,000,000 | Poised & Spontaneous | RGB & BGR | 6 basic emotions + Neutral                          | One annotator per image      |
| RAF-DB [5], [6] | Web         | 29,673    | Poised & Spontaneous | RGB & BGR | 6 basic emotions + Neutral and 12 compound emotions | 40 Independent annotators    |
| FER-2013 [7]    | Web         | 32,298    | Spontaneous          | BGR       | 6 basic emotions + Neutral                          | Image search API             |
| CK+ [8]         | Lab         | 593       | Poised & Spontaneous | RGB & BGR | 6 basic expressions + Neutral + Contempt            | FACS coded by two annotators |

Fig. 1. Progreso de la precisión de la predicción por época



Fig. 2. Progreso del valor de pérdida

#### 1.4 CNN y reconocimiento de rostros

Los últimos estudios han tenido como objetivo adaptar los modelos más avanzados existentes a algoritmos compactos. MobileNetV1 Howard et al. (2017) fue desarrollado por el equipo de Google Brain para obtener un rendimiento más eficiente con una estructura más compacta. Es casi tan preciso (en ImageNet) como VGG16 y es 32 veces más pequeño. Luego, un modelo mejorado, es decir, MobileNetV2 Sandler et al. (2018), superó a MobileNetV1 en ImageNet con menos parámetros. Además, ShuffleNet Zhang et al. (2017) y EfficientNet Yang et al. (2019) también lograron un rendimiento similar con parámetros bajos.

## 2. METODOLOGÍA

En este estudio, analizamos la precisión por clase para probar la precisión general, caracterizada como la proporción de clasificaciones correctas con respecto al conjunto total de muestras. Esto incluyó determinar la cantidad de clasificaciones correctas atribuidas a cada una de 5 categorías emocionales diferentes. Esta estrategia es uno de los métodos más utilizados en la literatura para medir el desempeño de modelos

### 2.1 Definición de la arquitectura

El modelo empleado es ilustrado en la figura 3:

Como primer paso podemos ver una capa de entrada: Considerando que las imágenes de entrada son de tamaño  $48 \times 48$  píxeles.

Se definió la primera capa convolucional (**conv2d\_3**): Esta capa utiliza un total de 48 filtros, cada uno de  $3 \times 3$  píxeles, con esta operación se reduce la dimensión de cada imagen.

Model: "sequential\_1"

| Layer (type)                        | Output Shape       | Param # |
|-------------------------------------|--------------------|---------|
| conv2d_3 (Conv2D)                   | (None, 46, 46, 48) | 1344    |
| max_pooling2d_2 (MaxPooling2D)      | (None, 23, 23, 48) | 0       |
| conv2d_4 (Conv2D)                   | (None, 21, 21, 48) | 20784   |
| max_pooling2d_3 (MaxPooling2D)      | (None, 10, 10, 48) | 0       |
| conv2d_5 (Conv2D)                   | (None, 8, 8, 96)   | 41568   |
| flatten_1 (Flatten)                 | (None, 6144)       | 0       |
| dense_2 (Dense)                     | (None, 96)         | 589920  |
| dense_3 (Dense)                     | (None, 5)          | 485     |
| Total params: 654101 (2.50 MB)      |                    |         |
| Trainable params: 654101 (2.50 MB)  |                    |         |
| Non-trainable params: 0 (0.00 Byte) |                    |         |

Fig. 3. Arquitectura del modelo

El siguiente paso fue definir la primera capa de pooling (**max\_pooling2d\_2**): En esta capa se aplicó un max pooling de  $2 \times 2$ , reduciendo así las dimensiones de la salida de la capa convolucional anterior de  $46 \times 46$  a  $23 \times 23$ .

Ahora se definió la segunda capa convolucional (**conv2d\_4**): Utilizando nuevamente 48 filtros de  $3 \times 3$  píxeles. Al igual que en la primera capa convolucional.

Se aplicó una segunda capa de pooling (**max\_pooling2d\_3**): Aplicando un max pooling de  $2 \times 2$ , reduciendo las dimensiones de la salida de la segunda capa convolucional.

Se integró una tercera capa convolucional (**conv2d\_5**): Incrementando el número de filtros a 96, utilizando filtros de  $3 \times 3$  píxeles.

El siguiente paso fue el aplanado (**flatten\_1**): Esta capa aplanó la salida de la última capa convolucional en un vector unidimensional de 6144 elementos (a este punto se tiene que son  $8 \times 8 \times 96$ ) para integrar a la capa densa.

Como se mencionó se agregó una capa densa (**dense\_2**): Una capa completamente conectada con 96 neuronas, que recibe el vector aplanado de la capa anterior.

Finalmente se agregó una segunda capa densa (**dense\_3**): Esta capa de salida constaba de 5 neuronas, correspondiente a las cinco categorías de emociones.

El modelo fue relativamente compacto con un total de 654,101 parámetros entrenables, lo cual indica un tamaño manejable para la tarea específica de reconocimiento de emociones con un conjunto limitado de categorías y una entrada de baja resolución.

### 2.2 Compilación del modelo

Se utilizó el optimizador 'adam' que como se sabe es un optimizador basado en la estimación adaptativa de momentos de primer y segundo orden. Se decidió utilizarlo debido a su eficacia en diferentes tipos de problemas de aprendizaje automático, ajustando la tasa de aprendizaje de cada parámetro de manera individual.

Como función de pérdida se seleccionó la función 'Sparse-CategoricalCrossentropy(from\_logits=True)'. Seleccionada ya que es adecuada para problemas de clasificación mul-

tielase (en este caso, los índices de las emociones). El argumento `from_logits=True` se asignó así para indicar que las salidas del modelo, que son 'logits', no estarán normalizadas, es decir, el modelo no incluye una capa 'Softmax' al final. Con esto a fin de que el modelo produzca directamente los logits, y la función de pérdida aplicará internamente la función 'softmax' para calcular la entropía cruzada.

Como métricas: Se monitorizó el 'accuracy' durante el entrenamiento y la evaluación del modelo.

### 2.3 Entrenamiento

Para el entrenamiento se exploraron diferentes números de épocas desde 10 hasta 300 épocas, sin embargo el `val_loss` no se logró optimizar por lo que se decidió asignar un valor de 20 épocas para mejores resultados.

Finalmente se guardó el modelo obtenido y se evaluaron distintos rostros.

### 2.4 Detección de rostros

Para facilitar la detección de rostros se utilizó `hardcascades` de la librería de OpenCV y se asignaron probabilidades de la emoción que correspondía el rostro de estudio.

## 3. RESULTADOS




Fig. 4. Resultados de detección de emociones en rostros

El modelo fue probado tanto en personas en vivo como en fotografías de personas (actores), para probar la habilidad del modelo de predecir correctamente las emociones (Fig.4).

### 3.1 Métricas obtenidas

Como podemos ver en las métricas obtenidas (Fig. 5) para 'happy' (2) y 'surprise' (4) son las emociones que el modelo identifica mejor, con alta precisión y recall. Indicando que el modelo es efectivo en reconocer estas emociones correctamente.

En cuanto a 'angry' (0), 'fear' (1) y 'sad' (3) tienen un rendimiento más bajo, con particular dificultad en 'sad' (3) donde el modelo tiende a no identificar suficientemente esta emoción (bajo recall).

En exactitud General el modelo tiene una exactitud global de 0.52, lo que significa que identifica correctamente la emoción más de la mitad de las veces en el conjunto de datos.

De manera que el modelo funcionó bien para algunas emociones como 'happy' y 'surprise', pero necesita mejoras para otras como 'sad' y 'fear'.

|                                 |           |        |          |         |
|---------------------------------|-----------|--------|----------|---------|
| 183/183 [=====] - 0s 810us/step |           |        |          |         |
|                                 | precision | recall | f1-score | support |
| 0                               | 0.40      | 0.47   | 0.43     | 958     |
| 1                               | 0.33      | 0.41   | 0.37     | 1024    |
| 2                               | 0.73      | 0.71   | 0.72     | 1774    |
| 3                               | 0.44      | 0.31   | 0.37     | 1247    |
| 4                               | 0.61      | 0.61   | 0.61     | 831     |
| accuracy                        |           |        | 0.52     | 5834    |
| macro avg                       | 0.50      | 0.50   | 0.50     | 5834    |
| weighted avg                    | 0.53      | 0.52   | 0.52     | 5834    |

Fig. 5. Métricas obtenidas

### 3.2 Matriz de confusión

En cuanto la matriz de confusión podemos ver de forma más explícita el rendimiento del modelo en cada una de las emociones, como podemos observar en la Fig.6, el modelo logra mayor probabilidad de predicciones correctas en emociones como 'happy' y 'suprise' con 0.70 y 0.69 respectivamente.




Fig. 6. Matriz de confusión

Sin embargo se muestran resultados más bajos para emociones como angry, fear y sad.

## 4. CONCLUSIÓN Y TRABAJO A FUTURO

El modelo tiene un rendimiento variable dependiendo de la emoción específica, siendo más efectivo con 'happy' y 'surprise' que con 'sad', 'Fear' y 'angry'. Esto puede indicar la necesidad de ajustes adicionales en el modelo o de considerar características adicionales que puedan ayudar a mejorar la clasificación de las emociones con peor desempeño.

Durante la investigación se exploraron modelos más complejos como ResNet-50, con pesos de modelos entrenados con datasets como ImageNet, técnicas para equilibrar el

`val_loss` como DataAugmentation, dropout, batch normalization, early stopping entre otros. Sin embargo los resultados fueron muy similares pero con tiempos de entrenamiento prolongados y `val_loss` mucho mayores por lo que se optó por utilizar una arquitectura más simple.

De manera que de trabajo a futuro se podría explorar trabajar con una base de datos más equilibrada con imágenes de mayor resolución o bien buscar extraer previamente más características que ayuden a fortalecer el aprendizaje del modelo durante el entrenamiento sobre cómo se pueden identificar las emociones en un rostro.

## REFERENCES

- Howard, A.G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., and Adam, H. (2017). Mobilenets: Efficient convolutional neural networks for mobile vision applications. *CoRR*, abs/1704.04861. URL <http://arxiv.org/abs/1704.04861>.
- Long, J., Shelhamer, E., and Darrell, T. (2015). Fully convolutional networks for semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, 3431–3440.
- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., and Chen, L.C. (2018). Mobilenetv2: Inverted residuals and linear bottlenecks. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 4510–4520. doi:10.1109/CVPR.2018.00474.
- Simonyan, K. and Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*.
- Szegedy, C., Ioffe, S., Vanhoucke, V., and Alemi, A. (2017). Inception-v4, inception-resnet and the impact of residual connections on learning. In *Proceedings of the AAAI conference on artificial intelligence*, volume 31.
- Yang, B., Bender, G., Le, Q.V., and Ngiam, J. (2019). Soft conditional computation. *CoRR*, abs/1904.04971. URL <http://arxiv.org/abs/1904.04971>.
- Zhang, X., Zhou, X., Lin, M., and Sun, J. (2017). Shufflenet: An extremely efficient convolutional neural network for mobile devices. *CoRR*, abs/1707.01083. URL <http://arxiv.org/abs/1707.01083>.